UNIVERSIDAD DE BUENOS AIRES
Facultad de Ciencias Económicas — Big Data y Machine Learning

Trabajo Práctico N° 2

Un primer encuentro con la EPH

Grupo 1 | Definición: Upper-tier informal wage employees

Repositorio GitHub: https://github.com/nahuelvp/BigDataUba-Grupo-1.git

Parte I — Familiarización con la EPH y limpieza

Ejercicio 1 — Identificación de trabajadores informales en la EPH

Según el INDEC, un trabajador asalariado es considerado informal cuando su empleador no realiza descuentos jubilatorios en su remuneración, es decir, trabaja 'en negro' sin registro previsional. Esta condición se identifica en la EPH mediante la variable PP07H, que registra si el trabajador tiene descuento jubilatorio por su trabajo (PP07H = 1: sí; PP07H = 2: no). Para nuestro caso, la definición de informalidad adoptada es la de Upper-tier informal wage employees según Maurizio & Monsalvo (2021): asalariados sin descuento jubilatorio que trabajan en establecimientos de más de cinco empleados, medido a través de la variable PP04C (tamaño del establecimiento).

Ejercicio 2 — Selección, armonización y limpieza de variables

2a. Selección y armonización de tipos de datos

Se seleccionaron 20 variables de interés que incluyen las obligatorias indicadas en la consigna más variables adicionales relevantes para el análisis de informalidad: PP03I (horas trabajadas) y PP07H (descuento jubilatorio). Al comparar los tipos de datos entre ambos años, se identificó una única inconsistencia: la variable CH08 (tipo de vivienda) figuraba como entero en 2024 y como decimal en 2025. Esta discrepancia fue corregida convirtiendo ambas versiones al tipo Int64, que admite valores nulos sin generar errores.

2b. Corrección de valores sin sentido

El proceso de limpieza se enfocó en las variables de ingreso P21 (ingreso de la ocupación principal) y P47T (ingreso total). Ambas presentaban valores de -9 que, según el diccionario de la EPH, corresponden a una codificación de no respuesta o no aplicabilidad — no a ingresos negativos reales. En 2024 se identificaron 3.403 casos en P21 y 4.862 en P47T; en 2025, 3.839 y 5.405 respectivamente. Estos valores fueron reemplazados por NaN en lugar de eliminarse, dado que las observaciones siguen siendo válidas para el resto de las variables. El mínimo resultante tras la limpieza es 0, correspondiente a personas sin ingresos declarados.

2c. Heatmap de valores faltantes

El heatmap de valores faltantes revela dos patrones bien diferenciados. Por un lado, las variables de identificación y características sociodemográficas no presentan valores faltantes en ninguno de los dos años, lo cual es consistente con el diseño de la EPH donde estas preguntas se aplican a todos los encuestados. Por otro lado, las variables vinculadas a las condiciones de empleo (EMPLEO, SECTOR, PP04C, PP04D_COD, PP03I) registran aproximadamente un 56% de valores faltantes en ambos años. Esto no constituye un error sino una característica del cuestionario: dichas preguntas únicamente se realizan a personas ocupadas, que representan aproximadamente el 44% de la muestra. Las variables de ingreso P21 y P47T presentan entre 7% y 12% de nulos, correspondientes a los valores -9 reemplazados durante la limpieza.

Figura 1: Porcentaje de valores faltantes por variable — EPH 2024 T1 y 2025 T1

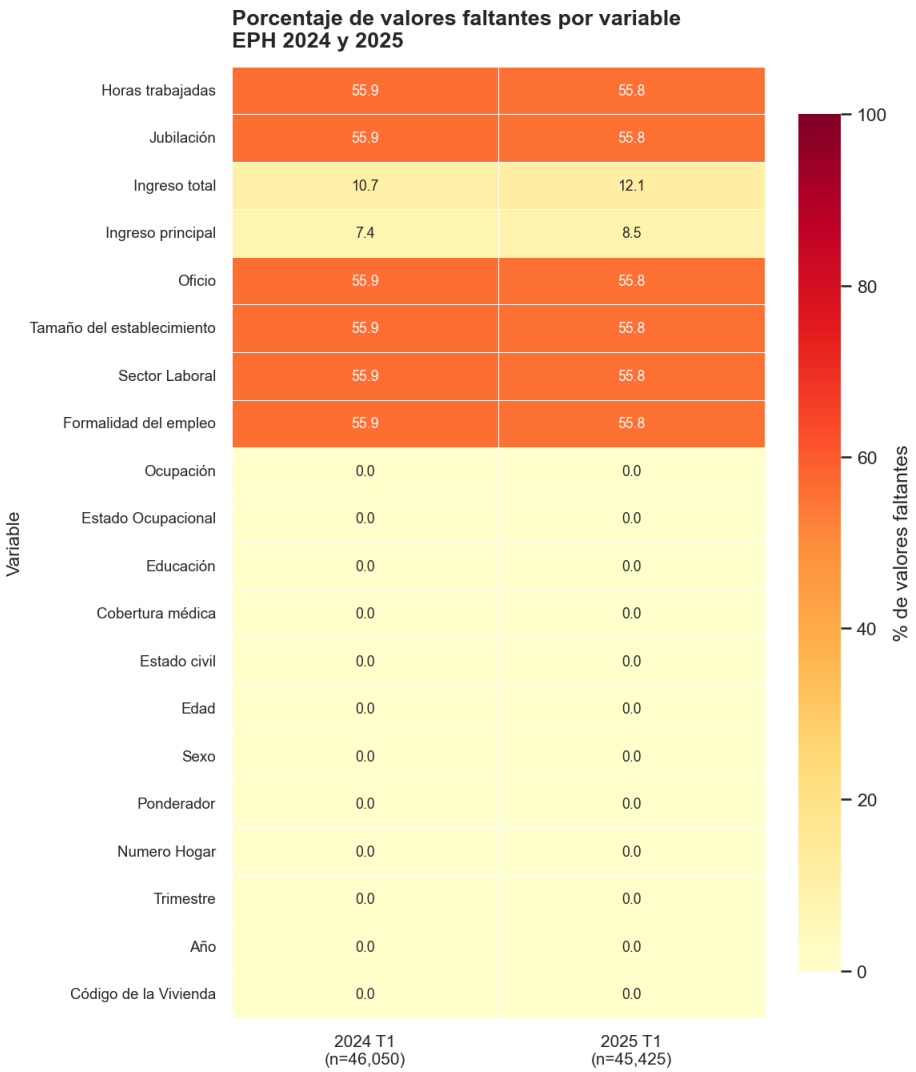

2d. Creación de variables dicotómicas

Para las variables categóricas seleccionadas se crearon variables dummy binarias con etiquetas descriptivas. Las variables dummificadas fueron: CH04 (es_mujer), ESTADO (es_ocupado, es_desocupado, es_inactivo), CAT_OCUP (es_asalariado, es_cuentapropista, es_patron), SECTOR (es_sector_privado) y NIVEL_ED (universitario, para quienes completaron estudios universitarios o superiores). En todos los casos se asignó el valor 1 a la categoría de interés y 0 al resto, permitiendo su uso directo en análisis estadísticos y modelos.

2e. Actualización de ingresos a pesos de 2025 T1

Los ingresos de 2024 T1 fueron convertidos a pesos de 2025 T1 utilizando el Índice de Precios al Consumidor (IPC) del INDEC. El factor de actualización resultante fue de 1.7861, equivalente a una inflación acumulada del 78.6% entre ambos períodos (IPC 2024 T1 = 1.992; IPC 2025 T1 = 3.558, base diciembre 2016 = 100). Las variables P21 y P47T de 2024 fueron multiplicadas por este factor, generando las variables P21_real y P47T_real comparables entre años.

Ejercicio 3 — Separación por respuesta a condición de actividad

Se identificaron 156 personas que no respondieron su condición de actividad (ESTADO = 0), representando apenas el 0.17% de las 91.475 observaciones totales. Esta tasa de no respuesta es muy baja y habla de la calidad del relevamiento de la EPH. Las observaciones restantes (91.319) fueron guardadas en la base respondieron, mientras que las 156 no respondientes se guardaron en no respondieron.

Ejercicio 4 — Filtro de personas ocupadas

Dentro de la base respondieron se seleccionaron únicamente las personas con ESTADO = 1 (ocupadas), conformando la base ocupados con 40.401 personas, equivalentes al 44.2% de quienes respondieron. Este porcentaje es consistente con los valores faltantes observados en el heatmap para las variables de empleo.

Parte II — Primer Análisis Exploratorio

Ejercicio 5 — Matriz de correlación

La matriz de correlación muestra resultados consistentes entre 2024 T1 y 2025 T1, lo que sugiere que la estructura del mercado laboral no cambió sustancialmente entre períodos. La correlación más fuerte se observa entre P21_real y P47T_real (0.77 en 2024 y 0.85 en 2025), lo cual es esperable dado que el ingreso total incluye al ingreso de la ocupación principal. La correlación entre ESTADO y CAT_OCUP es muy alta en valor absoluto (-0.92) pero refleja principalmente la codificación numérica de ambas variables y no una relación económica directa. La relación entre nivel educativo (NIVEL_ED) e ingreso (P21_real) es positiva pero moderada (0.21-0.22), consistente con mercados laborales donde la informalidad debilita el retorno a la educación. Las correlaciones no muestran cambios significativos entre 2024 y 2025.

Figura 2: Matrices de correlación — EPH 2024 T1 y 2025 T1

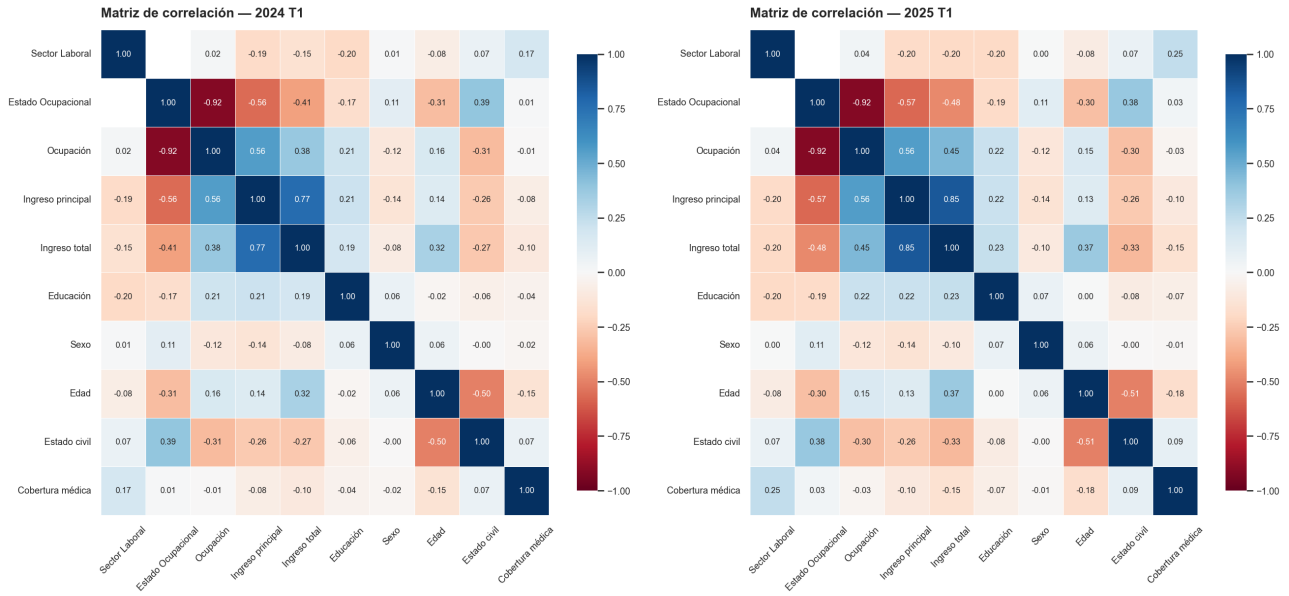

Ejercicio 6 — Estadística descriptiva

La tabla de estadística descriptiva fue calculada sobre la base respondieron para ambos años. Las variables de ingreso real (P21_real y P47T_real) muestran alta dispersión — el desvío estándar supera ampliamente a la media — lo que es característico de distribuciones de ingresos con colas largas. Las variables categóricas muestran estabilidad entre años, confirmando que la estructura de la muestra es comparable entre períodos. La tabla completa con los 10 estadísticos solicitados (N, media, desvío, mínimo, P1, P25, mediana, P75, P99 y máximo)

Parte III — Conociendo la informalidad laboral

Ejercicio 7 — Indicador de informalidad Upper-tier

Siguiendo la definición de Maurizio & Monsalvo (2021), se identificaron como Upper-tier informales a los asalariados sin descuento jubilatorio (PP07H = 2) que trabajan en establecimientos de más de cinco empleados (PP04C ≥ 6, excluyendo el código 99 de no respuesta). Los trabajadores con PP07H = 0 fueron excluidos por corresponder a no asalariados a quienes no aplica la pregunta. Los resultados muestran que la informalidad Upper-tier se redujo del 15% al 14% entre 2024 T1 y 2025 T1. En ambos períodos los varones presentan mayor informalidad que las mujeres — 15.3% vs 14.7% en 2024 y 14.8% vs 13% en 2025 — sugiriendo una composición sectorial diferenciada por género. La caída general podría reflejar una mayor formalización en empresas medianas y grandes, aunque la magnitud del cambio es moderada.

Tabla 1: Porcentaje de trabajadores formales e informales por sexo y año

Grupo	Total asalariados	Upper-tier informal (%)	Formal (%)
Total — 2024	11.328	**15%**	85%
Mujeres — 2024	5.076	**14.7%**	85.3%
Varones — 2024	6.252	**15.3%**	84.7%
Total — 2025	10.821	**14%**	86%
Mujeres — 2025	4.810	**13%**	87%
Varones — 2025	6.011	**14.8%**	85.2%

Ejercicio 8 — Distribución de ingresos: formales vs Upper-tier informales

Los histogramas y las curvas kernel muestran diferencias claras en la distribución de ingresos entre los asalariados formales y los upper-tier informales. En ambos casos — tanto para el ingreso de la ocupación principal (P21) como para el ingreso total (P47T) — los upper-tier informales presentan una distribución más concentrada en niveles de ingreso relativamente bajos, con mayor densidad en los primeros tramos y una caída más rápida a medida que aumentan los ingresos. Los formales, en cambio, exhiben una distribución desplazada hacia la derecha, con mayor presencia en niveles de ingreso medios y altos, además de colas más largas, lo que sugiere una mayor dispersión y una participación más importante en los tramos superiores de ingresos.

Estas diferencias se observan de manera consistente en los cuatro gráficos: los histogramas permiten ver la mayor concentración relativa de los upper-tier informales en los niveles bajos, mientras que las curvas kernel muestran con más claridad que la distribución de los formales está ubicada más a la derecha y se extiende sobre un rango más amplio de ingresos.

Además, para construir esta comparación fue necesario aplicar un filtro adicional en el código, separando primero a los under/lower-tier informales y dejando luego únicamente los dos grupos que exige la consigna: formales y upper-tier informales. Este paso se realizó para evitar sesgos en la comparación final y asegurar que el análisis quedara más limpio y consistente con el objetivo del ejercicio.

.

Figura 3: Distribución de ingresos — Formales vs Upper-tier Informales (EPH 2024 T1)

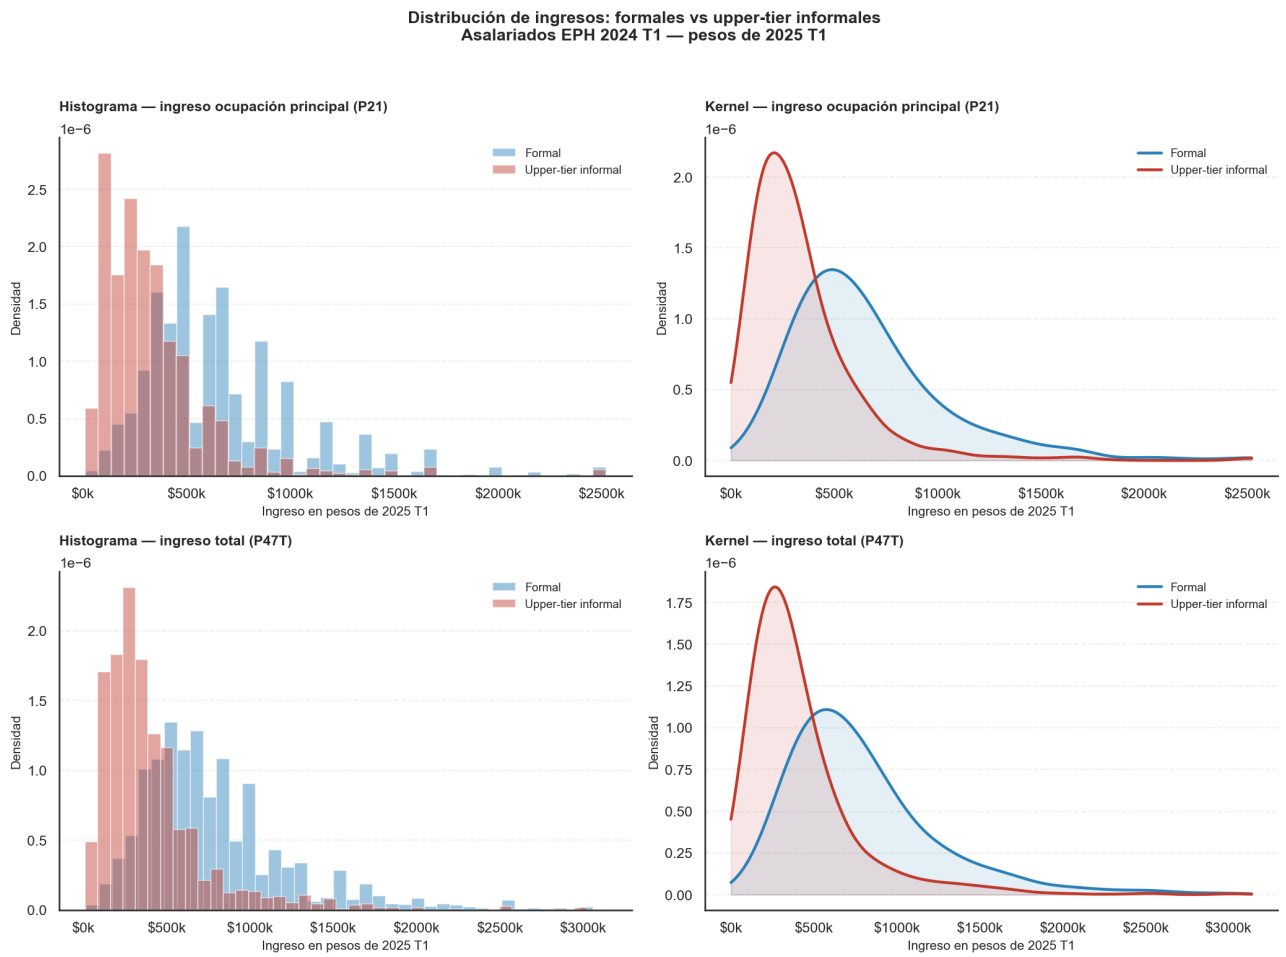

Parte IV — Herramientas de IA y reflexión final

Reflexión sobre el uso de IA

La IA ayudó principalmente en la armonización de datos entre los distintos años y en la construcción de gráficos. Fue útil para ordenar el código, detectar diferencias en tipos de variables y mejorar la parte visual del trabajo. Su aporte fue más técnico que analítico.