Trabajo Práctico N° 3

Grupo 1 | Definición: Upper-tier informal wage employees

Integrantes: Juan Cruz Pombo, Nahuel Vasquez

Repositorio GitHub: https://github.com/nahuelvp/BigDataUba-Grupo-1.git

Parte I — Creación de Variables y Estadística Descriptiva

Consigna 1 — Creación de Variables

1a. Variable edad²

Se creó la variable edad2 como el cuadrado de la edad (CH06²). Esta transformación permite capturar la relación no lineal entre edad e ingresos — típicamente los ingresos crecen con la edad pero a una tasa decreciente, formando una parábola invertida. Incluir edad² junto con edad en un modelo permite estimar ese efecto cuadrático.

1b. Variable educ — Años de educación formal

Se construyó la variable educ combinando tres variables del cuestionario EPH: CH12 (nivel educativo más alto alcanzado), CH13 (¿completó ese nivel?) y CH14 (último año aprobado dentro del nivel). La lógica aplicada asigna años base según el nivel alcanzado siguiendo el sistema educativo argentino — primaria completa = 7 años, secundario completo = 12, universitario completo = 17 — y suma los años cursados según CH14 cuando el nivel no fue completado (CH13 = 2).

Tabla 1: Estadística descriptiva de educ — años de educación formal

Año	N	Media	Desvío	Mín	P25	Mediana	P75	Máx
2024 T3	47.509	9.89	5.10	0	7	12	12	22
2025 T3	44.882	9.99	5.03	0	7	12	12	22

La media de años de educación es de aproximadamente 10 años en ambos períodos, equivalente a primaria completa más algunos años de secundario. El hecho de que tanto la mediana como el P75 sean 12 años indica una fuerte concentración en el umbral de secundario completo: la mitad de la muestra tiene exactamente 12 años de educación y solo el 25% superó ese nivel. El mínimo de 0 corresponde a personas sin instrucción formal y el máximo de 22 a estudios de posgrado. La distribución es prácticamente idéntica entre 2024 y 2025, lo que es esperable dado que el nivel educativo es una variable de stock que se acumula lentamente.

1c. Variable horastrab — Horas totales trabajadas

Se creó horastrab como la suma de las horas trabajadas en la ocupación principal (PP3E_TOT) y en otras ocupaciones (PP3F_TOT), calculada exclusivamente para el jefe de hogar (CH03 = 1). Los valores codificados como 999 en las variables de horas fueron reemplazados por NaN por corresponder a no respuesta según el diccionario del INDEC.

1d. Variable nhogar — Miembros por hogar

Se calculó nhogar como el conteo de componentes (COMPONENTE) por hogar, identificando cada hogar mediante la combinación de CODUSU y NRO_HOGAR. Esta variable captura el tamaño del hogar y puede ser relevante como proxy de cargas familiares que afectan la oferta laboral.

Consigna 2 — Estadística Descriptiva

La tabla de estadística descriptiva completa con N, media, desvío estándar, mínimo, P25, mediana, P75 y máximo para todas las variables limpias del TP2 y las nuevas variables creadas se presenta a continuación para 2024 T3 y 2025 T3.

Estadística descriptiva — EPH 2024 T3

Variables seleccionadas · Base ocupados

VARIABLE	N	MEDIA	DESVÍO	MÍN	P25	MEDIANA	P75	MÁX
edad	47,163	36.74	22.05	1	18	34	53	104
edad²	47,163	1,836.32	1,852.14	1	324	1,156	2,809	10,816
educ	47,509	9.89	5.10	0	7	12	12	22
horastrab	10,398	38.19	17.17	0	30	40	48	130
nhogar	47,509	5.42	3.52	1	3	4	7	27
P21	43,474	204,902	413,372	0	0	0	300,000	12,000,000
P47T	41,821	338,310	526,837	0	0	200,000	490,000	23,042,000
PP04C	21,031	16.78	31.36	0	1	6	9	99
NIVEL_ED	47,509	3.76	1.76	1	3	4	5	7
CAT_OCUP	47,509	1.26	1.40	0	0	0	3	9
ESTADO	47,509	2.20	1.13	1	1	3	3	4
CH04	47,509	1.52	0.50	1	1	2	2	2
CH07	47,509	3.52	1.65	1	2	5	5	9
CH08	47,509	2.17	1.82	1	1	1	4	23

La muestra cuenta con alrededor de 47.500 observaciones, aunque variables como *horastrab*, *P21*, *P47T* y *PP04C* presentan valores faltantes por corresponder solo a ocupados o jefes de hogar. La edad promedio es de 37 años con alta dispersión, y la educación promedio ronda los 10 años, con una mediana de 12 que indica que al menos la mitad completó el secundario. Las variables de ingreso (*P21* y *P47T*) exhiben una marcada asimetría positiva mediana de P21 igual a 0 frente a una media de $204.902 evidenciando la presencia de outliers de altos ingresos. Las variables categóricas presentan rangos acotados, consistentes con su naturaleza discreta.

Consigna 3 — Matriz de Correlaciones 2025 T3

Se calculó la matriz de correlaciones para la base de ocupados de 2025 T3 con las variables: informal, edad, edad2, educ, horastrab, nhogar, P21 y PP04C.

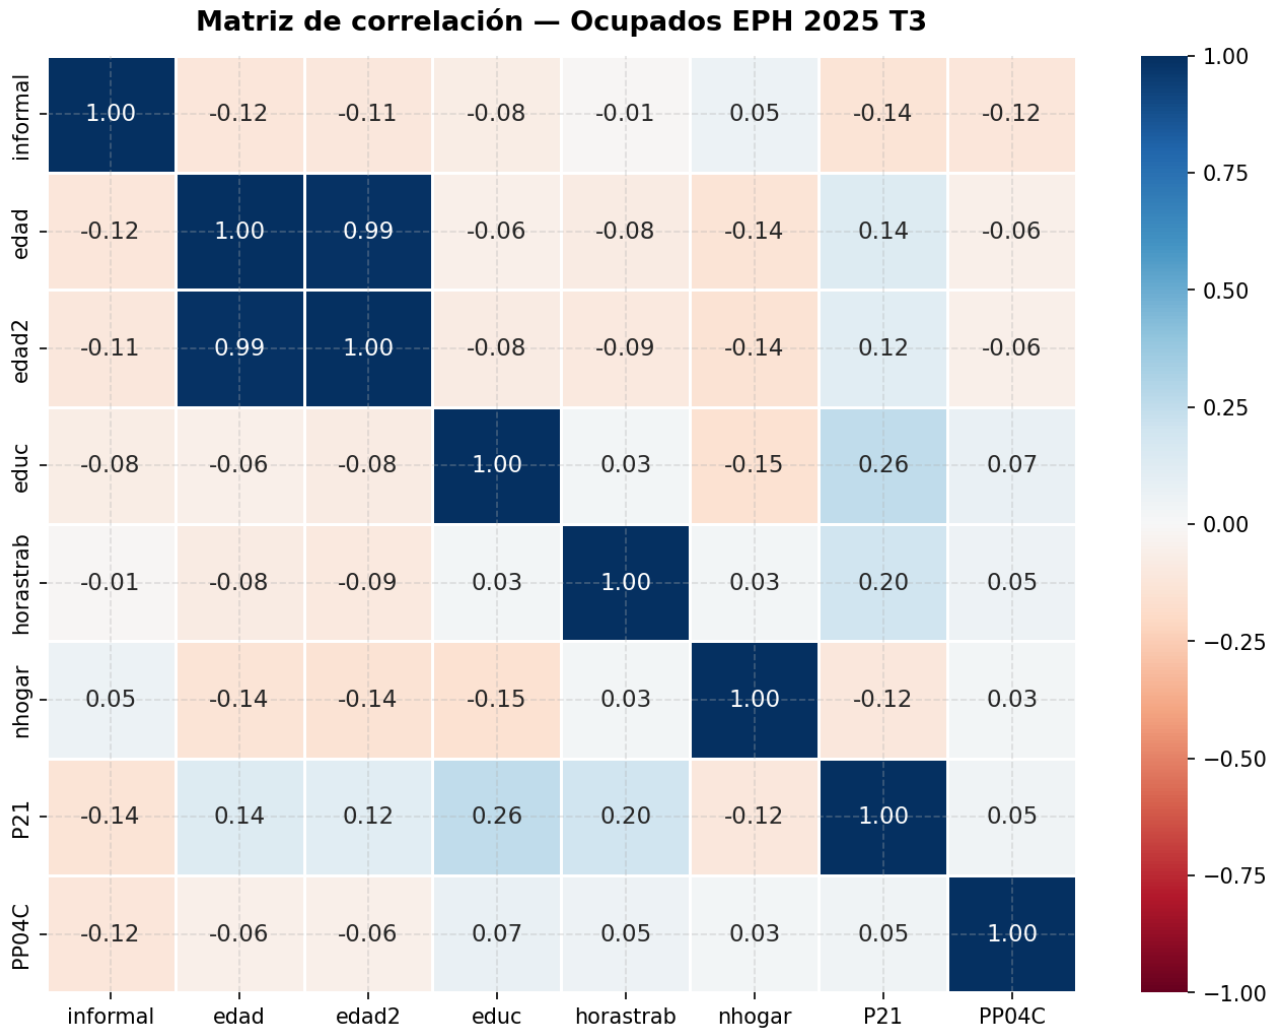

En la matriz se ve que la relación más fuerte es entre edad y edad2, con una correlación de 0.99, algo esperable porque edad2 sale directamente de la edad. Sacando ese caso, las demás correlaciones son bastante bajas. La variable informal no parece estar muy relacionada con las otras variables: tiene correlaciones negativas chicas con P21 (-0.14), edad (-0.12), edad2 (-0.11), PP04C (-0.12) y educ (-0.08). Esto quiere decir que ser informal no se explica fuertemente por una sola variable de la matriz, al menos mirando la relación lineal. También se observa que P21 tiene una relación positiva con educ (0.26) y con horastrab (0.20), lo cual tiene sentido porque más educación y más horas trabajadas pueden asociarse con mayores ingresos. En general, la matriz muestra un contexto de baja correlación entre la mayoría de las variables, salvo edad y edad2. Esto sirve para la parte del PCA, porque indica que probablemente no haya componentes principales que concentren muchísima información por sí solos.

Parte II-A — PCA: Análisis de Componentes Principales

¿Qué es PCA? El Análisis de Componentes Principales (PCA) es un método no supervisado de reducción de dimensionalidad. Dadas p variables originales, PCA encuentra nuevos ejes (componentes principales) que maximizan la varianza explicada. El primer componente (PC1) captura la dirección de mayor varianza en los datos; el segundo (PC2) captura la mayor varianza restante siendo perpendicular al primero. Al proyectar los datos sobre los primeros 2 o 3 componentes se puede visualizar la estructura de los datos sin perder demasiada información. Es fundamental estandarizar las variables antes de aplicar PCA para que diferencias de escala no distorsionen los componentes.

Consigna II.A.1 Scores: PC1 vs PC2

El gráfico de scores muestra las coordenadas de cada persona en el nuevo sistema de ejes definido por los componentes principales. Cada punto es un asalariado, coloreado en azul si es formal y en rojo si es Upper-tier informal.

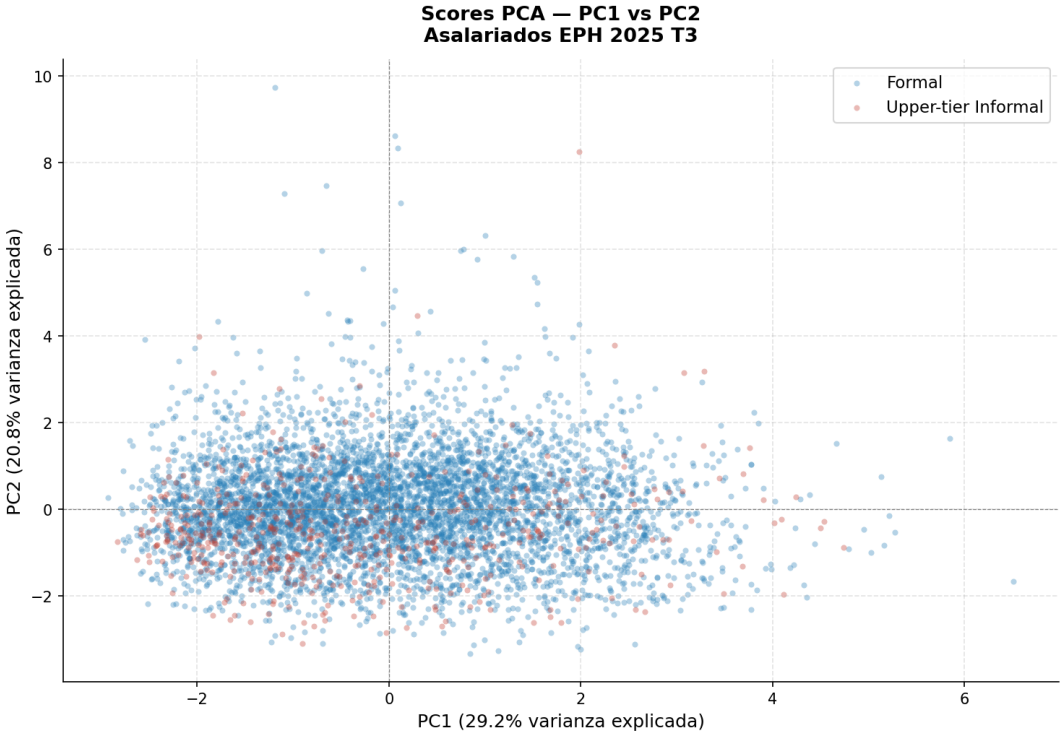

El gráfico muestra que PC1 y PC2 explican conjuntamente el 50% de la varianza. No se observa una separación clara entre trabajadores formales e informales en el espacio PC1-PC2: ambos grupos se solapan ampliamente en el centro de la nube, lo que sugiere que las variables utilizadas no logran discriminar la informalidad a través de estos dos componentes. Se identifican algunos outliers alejados del centro, principalmente en valores altos de PC1 y PC2, que podrían corresponder a individuos con ingresos o antigüedad laboral inusualmente elevados.

Consigna II.A.2 — Loadings: ponderadores de cada variable

El gráfico de loadings (biplot de flechas) muestra el peso que tiene cada variable original en los dos primeros componentes. Una flecha larga indica que esa variable contribuye fuertemente al componente en esa dirección. Flechas apuntando en la misma dirección indican variables correlacionadas entre sí; flechas opuestas indican correlación negativa; flechas perpendiculares indican independencia.

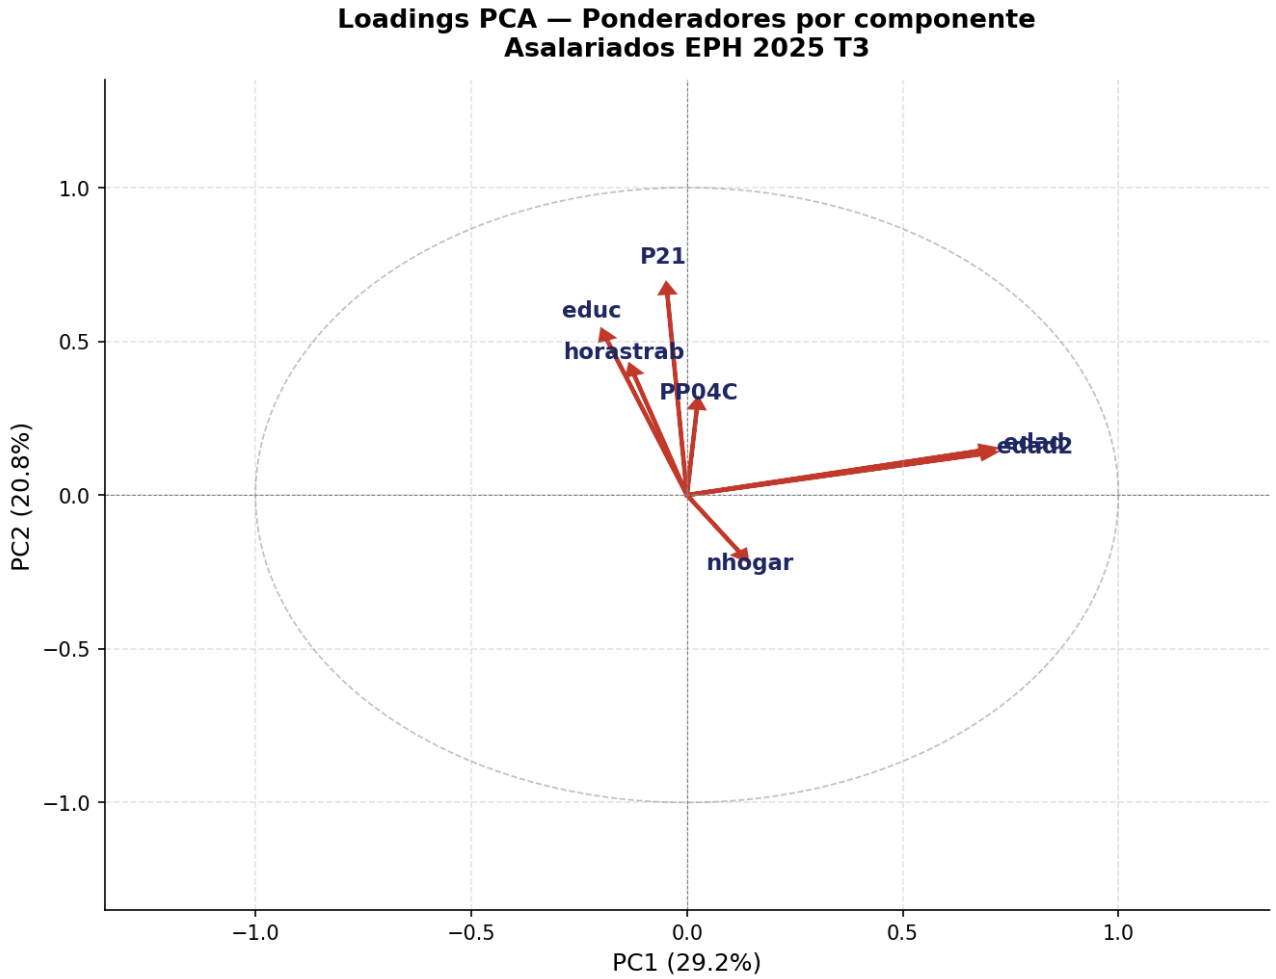

PC1 está dominado por *edad* y *edad²*, cuyas flechas apuntan en la misma dirección y con gran longitud, lo cual es esperable dado que ambas variables están perfectamente correlacionadas. PC2, en cambio, es capturado principalmente por *P21* (ingreso laboral), *educ* y *horastrab*, que apuntan hacia arriba con pesos similares. *nhogar* apunta levemente hacia abajo, indicando una leve correlación negativa con las anteriores. La mayoría de las flechas tienen longitud moderada y no alcanzan el borde del círculo unitario, lo que es consistente con el bajo nivel de correlación general observado en la matriz de la Parte I.

Consigna II.A.3 — Scree plot: varianza explicada por componente

El scree plot muestra la proporción de varianza total capturada por cada componente principal. Las barras representan la varianza individual de cada componente y la línea roja la varianza acumulada. El criterio más común para elegir cuántos componentes conservar es el del 80% acumulado — se retienen los componentes necesarios para superar ese umbral.

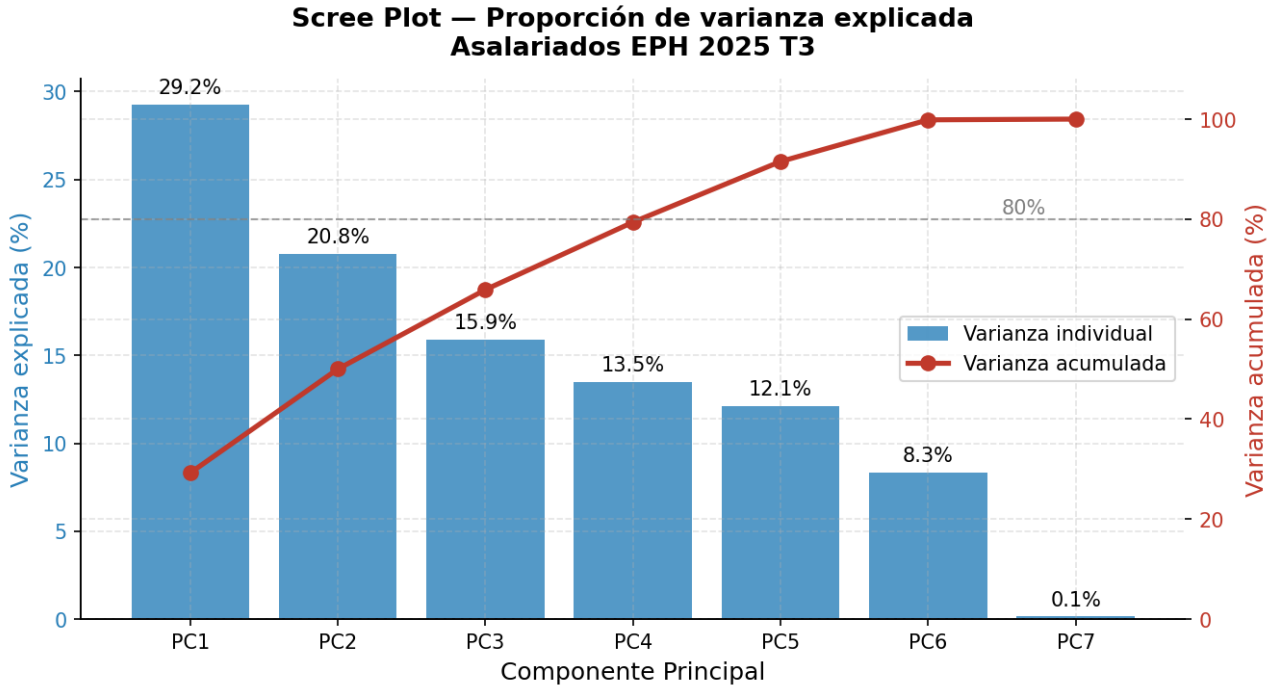

La varianza se distribuye de forma relativamente uniforme entre los primeros seis componentes, siendo necesarios cinco para superar el umbral del 80% acumulado (91.5% con PC5). Ningún componente domina ampliamente: PC1 explica solo el 29.2% y la caída entre componentes es gradual, sin un codo pronunciado. Esto es consistente con el contexto de baja correlación entre predictores observado en la Parte I: cuando las variables comparten poca información, el PCA no logra concentrar la varianza en pocos ejes y necesita más componentes para capturar la estructura de los datos.

Parte II-B — Clustering

Consigna II.B.4a — K-Means con k=2

¿Qué es K-Means? K-Means es un algoritmo de clustering que agrupa las observaciones en k grupos minimizando la distancia intra-cluster. El algoritmo arranca con k centroides aleatorios, asigna cada punto al centroide más cercano, recalcula los centroides como promedios de sus grupos y repite hasta convergencia. Se corrió con n_init=20 (20 inicializaciones distintas) para evitar soluciones subóptimas por elección de centroides iniciales desfavorables.

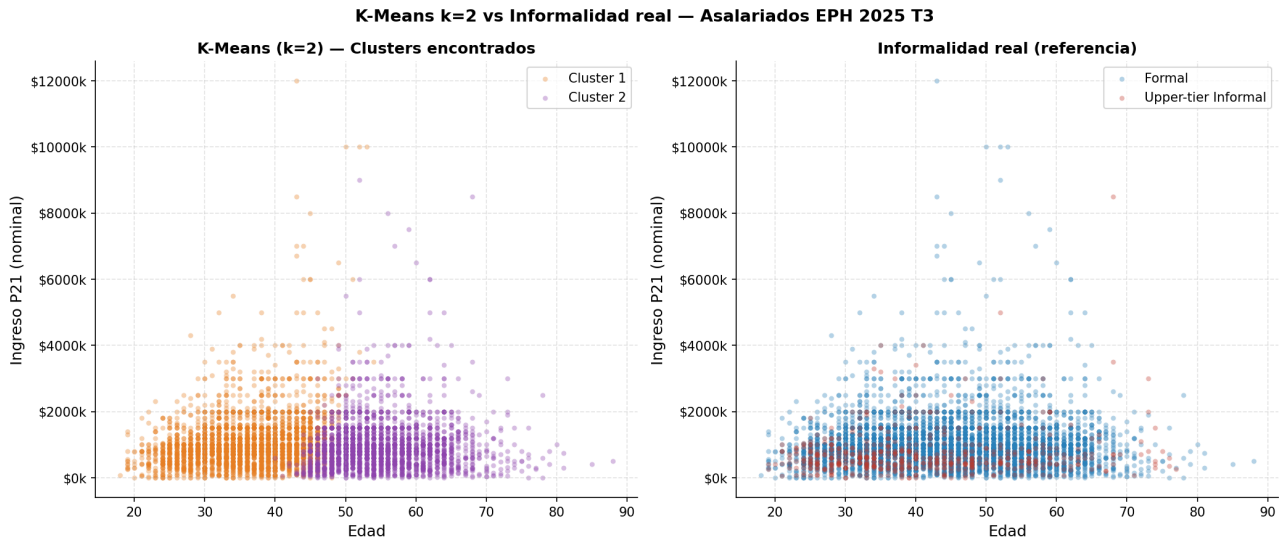

Los dos clusters encontrados por K-Means no se corresponden con la distinción formal/informal: comparando ambos paneles, la separación del algoritmo parece responder principalmente al nivel de ingresos (P21) y no a la condición de informalidad, que se distribuye de forma mezclada en ambos grupos. Esto sugiere que con k=2 el algoritmo captura la heterogeneidad en ingresos más que la formalidad laboral. La dificultad para separar ambas categorías es consistente con lo observado en el PCA: las variables disponibles no contienen suficiente señal para discriminar formales de informales en el espacio multivariado.

Consigna II.B.4b — Método del Codo (Elbow)

El método del codo determina el número óptimo de clusters graficando la inercia (suma de distancias al cuadrado de cada punto a su centroide) para k=1 hasta k=40. La inercia cae monótonamente al aumentar k — el punto donde la caída se hace más gradual forma el 'codo' y sugiere el k óptimo desde el cual agregar más clusters mejora poco la compacidad interna.

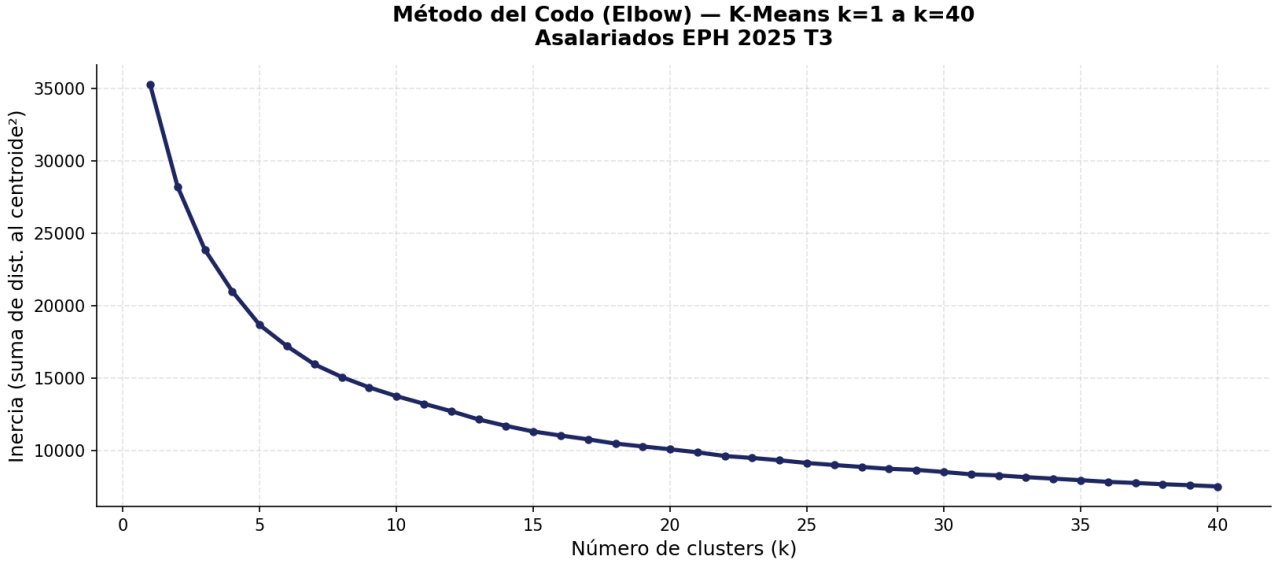

La curva de inercia cae bruscamente entre k=1 y k=5, y luego se aplana de forma gradual sin mostrar un quiebre nítido. El codo se ubica aproximadamente en k=5, donde la ganancia marginal de agregar un cluster adicional comienza a ser marginal. Sin embargo, el codo es ambiguo: la curva desciende de manera suave y continua, lo que dificulta identificar un k óptimo claro. Esto es nuevamente consistente con la baja correlación entre variables y la ausencia de agrupamientos naturales bien definidos en los datos.

Consigna II.B.5 — Clustering Jerárquico y Dendrograma

¿Qué es un dendrograma? El dendrograma es la representación visual del clustering jerárquico un árbol donde cada hoja es una observación. El algoritmo parte de cada persona en su propio grupo y va fusionando los dos grupos más similares en cada paso. El eje Y del dendrograma indica la disimilitud en el momento de la fusión: fusiones bajas ocurren entre elementos muy similares; fusiones altas ocurren entre grupos ya muy distintos. Cortando el árbol a distintas alturas se obtiene distintos números de clusters. Se utilizó el método Ward que minimiza la varianza intra-cluster en cada fusión.

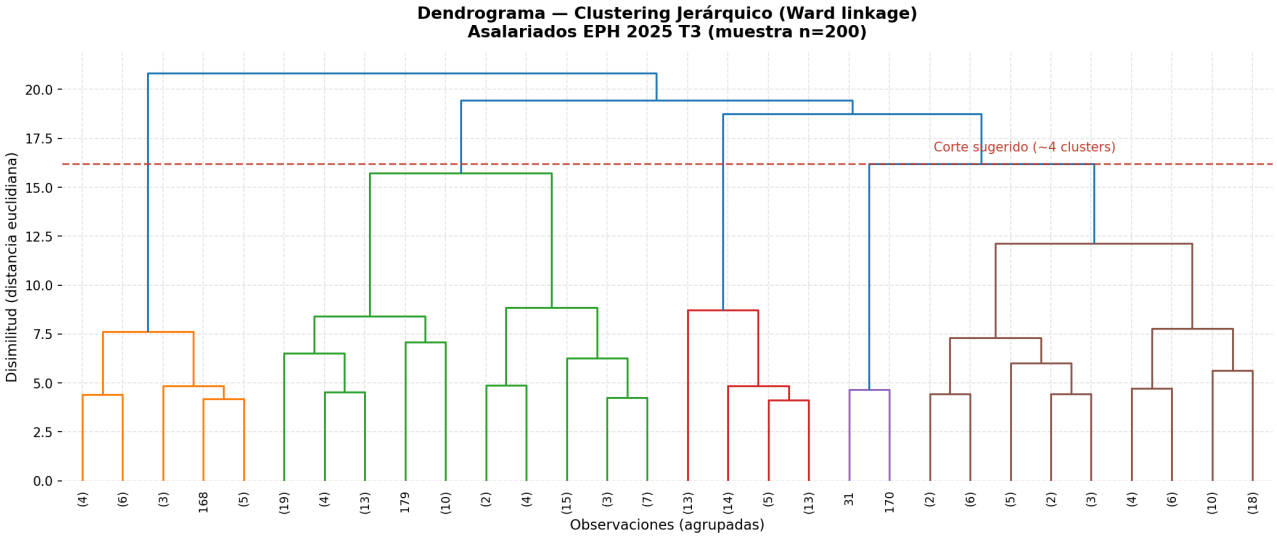

El dendrograma muestra que la primera gran fusión entre grupos ocurre a una altura de aproximadamente 20, sugiriendo la existencia de dos macro-grupos bien diferenciados. El corte sugerido a altura ~16 (línea roja punteada) resulta visualmente razonable y delimita aproximadamente 4 clusters, consistente con el k=5 sugerido por el método del codo. Las fusiones internas dentro de cada cluster ocurren a distancias bajas, indicando subgrupos relativamente compactos. En conjunto, ambos métodos convergen en que la estructura natural de los datos se captura mejor con entre 4 y 5 grupos que con solo 2.

Reflexión sobre el uso de IA

Claude nos ayudó durante el TP sobre todo en la parte de armonización de datos, limpieza de la base y armado de gráficos. Fue útil para ordenar el código, revisar cómo compatibilizar variables de distintos años de la EPH, detectar posibles errores y mejorar la forma de presentar los resultados visualmente. También nos sirvió para resolver dudas puntuales de programación. Sin embargo, lo más difícil fue usar la IA para interpretar los gráficos, especialmente en PCA y clustering, porque los resultados no se explican solos y requieren entender qué está pasando con los datos y relacionarlo con el contexto laboral de la EPH.

Tiempo total dedicado (8h – 10h semanales)

Apéndice — Prompts de IA utilizados

“hola, estoy haciendo un tp de big data con la EPH del indec y tengo que crear una variable que se llame educ que represente los años de educacion formal de cada persona. tengo las variables CH12 CH13 y CH14 pero no entiendo bien como combinarlas, CH12 es el nivel educativo, CH13 si lo completo y CH14 el ultimo año aprobado. como armo eso en python? el sistema educativo argentino tiene primaria de 7 años, secundario de 5 y despues universitario”

“me esta dando este error cuando trato de propagar variables nuevas a mi dataframe de ocupados: KeyError: '[92505, 92507...] not in index'. lo que hice fue crear variables nuevas en el dataframe respondieron y despues quise pasarlas a ocupados con .loc pero me da ese error. entiendo que tiene que ver con los indices pero no se como resolverlo”

“una pregunta conceptual, en el scree plot que hice para el PCA me sale que necesito 5 componentes para llegar al 80% de varianza explicada, y la varianza esta bastante distribuida entre los primeros 5 (29%, 21%, 16%, 14%, 12%). la consigna me pide comentar esto en relacion a las correlaciones que vi antes entre las variables. no entiendo bien la conexion entre las dos cosas, me podes explicar?"