

TP4 — Clasificando informales en la EPH

Grupo 1
Repositorio GitHub: <https://github.com/nahuelvp/BigDataUba-Grupo-1.git>

Objetivo. Predecir si un trabajador asalariado es informal a partir de sus características personales y laborales, usando la encuesta de 2024 para entrenar el modelo y la de 2025 para evaluarlo. Siguiendo a Maurizio & Monsalvo (2021), se evalúa además si conocer la situación de informalidad del año anterior mejora la predicción. Un trabajador se considera informal cuando, siendo asalariado en un establecimiento de más de cinco personas, no se le realiza el descuento jubilatorio.

Construcción de la base y características de la muestra

A partir de la base de ocupados se retuvo al universo de trabajadores asalariados, único grupo donde la definición de informalidad es aplicable, y se conservaron seis características: edad, años de educación, ingreso de la ocupación principal (deflactado a precios constantes), horas trabajadas, tamaño del hogar y tamaño del establecimiento. Se incorporó además el término edad al cuadrado, que no es una variable independiente sino una transformación de la edad: presenta un alto índice de correlación lineal con ella porque captura, de forma determinística, la relación no lineal entre edad e informalidad. La muestra se dividió en dos conjuntos: 2024 como entrenamiento (6.196 asalariados) y 2025 como evaluación (5.686). Para la extensión de Maurizio & Monsalvo se vinculó a cada persona consigo misma entre ambos años —mediante sus identificadores de vivienda, hogar y componente— para sumar su situación de informalidad previa; este cruce conserva 1.781 personas (el 31,3% de 2025), ya que la encuesta renueva parte de los hogares entre olas.

La Tabla 1 resume las características promedio en cada año y contrasta si las diferencias entre 2024 y 2025 son estadísticamente significativas (test t de Welch, $\alpha = 0,05$)

Característica	Promedio 2024	Promedio 2025	Diferencia	¿Significativa?
Edad (años)	43,8	44,5	+0,7	Sí ***
Años de educación	12,7	12,8	+0,04	No
Ingreso de la ocupación principal	\$878,621	\$1.013,5	+\$134,879	Sí ***
Horas trabajadas	38,0	38,4	+0,4	No
Tamaño del hogar	4,2	4,3	+0,03	No
Tamaño del establecimiento	14,6	15,0	+0,4	No

¿Hay diferencias estadísticas significativas entre las medias de cada año?

Sí, en parte. De las seis características, tres muestran diferencias significativas al 1%: la edad (sube de 43,8 a 44,5 años), la edad al cuadrado y, sobre todo, el ingreso laboral, que crece un 15% en términos reales. Las demás — educación, horas trabajadas, tamaño del hogar y del establecimiento— se mantienen estables. Estas diferencias son esperables en una encuesta que renueva parte de su muestra cada año y no invalidan el ejercicio: justamente buscamos comprobar si un modelo entrenado en un año mantiene su capacidad predictiva al año siguiente.

Modelo de regresión logística

Se estimaron dos modelos. El Modelo 1 predice la probabilidad de informalidad usando únicamente las características personales y laborales. El Modelo 2 agrega una variable: si la persona era informal el año anterior. La Tabla 2 reporta, para cada modelo, el efecto estimado (coeficiente), su error estándar y el odds-ratio, que indica en cuánto se multiplican las probabilidades de ser informal ante un aumento de esa característica (mayor a 1 las aumenta; menor a 1, las reduce)


Característica	Modelo 1 (sin historial)			Modelo 2 (con historial)		
	Coef.	Error	OR	Coef.	Error	OR
Edad	-0,110	0,023	0,896	-0,155	0,071	0,857
Edad al cuadrado	0,0009	0,0003	1,001	0,0014	0,0008	1,001
Años de educación	-0,009	0,013	0,991	-0,051	0,032	0,950
Ingreso ocup. principal	≈0	0,000	1,000	≈0	0,000	1,000
Horas trabajadas	0,004	0,003	1,004	0,009	0,007	1,009
Tamaño del hogar	0,024	0,016	1,024	-0,006	0,037	0,994
Tamaño del establecim.	-0,015	0,003	0,986	-0,025	0,009	0,976
Informal el año anterior	—	—	—	3,699	0,230	40,41
Constante	1,496	0,494	4,463	1,113	1,561	3,043

¿Cambian mucho los coeficientes de edad o educación al introducir el estatus de informalidad?

Sí, especialmente el de educación. El efecto de los años de educación se multiplica por más de cinco al pasar del Modelo 1 (coef. -0,009; prácticamente nulo y no significativo) al Modelo 2 (coef. -0,051). El de la edad también se intensifica (de -0,110 a -0,155). La interpretación es clave: cuando no se controla por el historial, el efecto educativo aparece diluido porque buena parte de la persistencia de la informalidad estaba siendo absorbida por otras variables. Al incorporar el antecedente, se separa el efecto propio de la educación del de la trayectoria. Y el resultado más contundente: el odds-ratio de “informal el año anterior” es 40,4 — haber sido informal multiplica por más de cuarenta las chances de volver a serlo. Esto confirma de forma rotunda el hallazgo central de Maurizio & Monsalvo: la informalidad es altamente persistente en el tiempo.

Probabilidad de informalidad según la edad


Se eligió la edad por ser la característica más interpretable para una audiencia no técnica. La línea roja muestra la probabilidad que estima el modelo; los puntos azules, la informalidad realmente observada en 2025. El patrón es muy claro: los trabajadores más jóvenes (18–25 años) tienen una probabilidad muy alta de ser informales — cercana al 40%—, que cae rápidamente y se estabiliza en torno al 10% en las edades centrales. Que la línea siga de cerca a los puntos confirma que el modelo, entrenado con datos de 2024, generaliza correctamente sobre 2025. Los valores dispersos en edades muy altas (más de 75 años) responden a que hay muy pocos trabajadores en esos tramos, por lo que cada caso individual mueve mucho el porcentaje. Implicancia de política: la informalidad se concentra en los jóvenes, de modo que un programa de formalización rinde más enfocándose en ellos.




Desempeño de los modelos y asignación de recursos

Para evaluar cada modelo se comparó su predicción sobre 2025 contra la situación real, con un umbral del 50%: si la probabilidad estimada supera ese valor, se clasifica a la persona como informal. La Figura 2 muestra los aciertos y errores; la Figura 3, la curva ROC, que resume la capacidad de distinguir informales con independencia del umbral.

Aciertos y errores de cada modelo (umbral 50%)



Indicador	Modelo 1	Modelo 2	Qué mide
Clasificaciones correctas (exactitud)	90,5%	93,8%	% de predicciones acertadas
Informales bien detectados (sensibilidad)	0%	54,7%	De los informales reales, cuántos detectó
Capacidad de discriminar (AUC)	0,705	0,881	Poder global de separar informales de formales



Interpretación de ambos modelos

El resultado más importante surge de no quedarse con el porcentaje de aciertos. El Modelo 1 tiene una exactitud del 90,5%, pero detectó CERO informales (0 de 542): como son una minoría, le “convino” predecir “formal” para todos y así acertar el 90%. Es un modelo inútil para el objetivo, pese a su exactitud alta. El Modelo 2, al incorporar el historial, detecta más de la mitad de los informales reales (75 de 137, 54,7%) y su capacidad de discriminar sube de 0,705 a 0,881. En la curva ROC, el Modelo 2 domina al Modelo 1 en todo el rango: para cualquier nivel de falsas alarmas tolerado, detecta más informales.

¿Qué modelo es mejor para asignar los recursos escasos del programa?

La Secretaría de Trabajo dispone de recursos limitados y enfrenta dos tipos de error con costos distintos:

- **Falsa alarma (error Tipo I):** marcar como informal a quien no lo es. El costo es destinar recursos a quien no los necesita.
- **Caso no detectado (error Tipo II):** marcar como formal a quien en realidad es informal. El costo es que el programa no llega al trabajador precarizado que se busca ayudar.

Para este objetivo conviene el Modelo 2. En una política de inclusión laboral el error más costoso socialmente es el Tipo II —dejar afuera al beneficiario—, por lo que la prioridad es maximizar la sensibilidad (detectar la mayor proporción de informales reales). El Modelo 1, con sensibilidad del 0%, es directamente inservible aquí; el Modelo 2 detecta el 54,7% y tiene mayor AUC (0,881 vs 0,705). Además, dado que los recursos son escasos, puede bajarse el umbral por debajo del 50% (por ejemplo a 30%) para ampliar la cobertura, eligiendo sobre la curva ROC el punto que mejor equilibre cuántos informales se alcanzan y cuánto presupuesto se destina a falsas alarmas.

Herramientas de IA y Prompts

"Esa tasa de informalidad que da el código (9.6% y 9.5%), ¿a qué tipo de informalidad corresponde, a la general o a la definición de nuestro grupo (upper-tier)? ¿Y es respecto al total de informales o respecto al total de trabajadores incluyendo formales?"

"En el vector y que armaste para el modelo, ¿es correcto que y_2024 e y_2025 incluyan a los formales? Tené en cuenta que hay otra categoría de asalariados informales (los de empresas con PP04C < 6) que en este código quedan fuera. Mirá lo que pide la consigna."

"Explicame conceptualmente qué representan los 1781 registros que quedan del inner join para construir ocupados_X_2025_MM. ¿Son datos que no estaban en 2024 y por eso no encontraron match? Pensá bien la respuesta, no me digas que sí solo para darme la razón."

"La tabla de diferencia de medias (t-test bilateral) no muestra el N de la muestra. No quiero una columna nueva, solo un N general en una línea de código, idealmente dentro de la tabla. Pasámelo por acá y yo lo edito."

"En el modelo logit con statsmodels, ¿cómo armo el filtro de filas sin NaN en ninguna X ni en y y reseteo el índice para evitar problemas de alineación entre el X y el y?"

"Para el inciso D armé las matrices de confusión con umbral 0.5. ¿Podés revisar que esté bien orientada (filas = real, columnas = predicho) y que esté usando el y de test y no el de train? Quiero estar seguro de no estar evaluando sobre los mismos datos con los que entrené"

"La tabla de 5 métricas (accuracy, precision, recall, F1, AUC) me da valores raros: recall muy bajo. ¿Tiene sentido dado que la clase informal está desbalanceada (~9.5%)? ¿Conviene comentar eso al interpretar, o estamos calculando mal alguna métrica"