

Trabajo Práctico N.º 5

Grupo 1

Repositorio de GitHub:

<https://github.com/nahuelvp/BigDataUba-Grupo-1>

Predecimos la **informalidad laboral** (EPH) con regresión logística regularizada, comparando el modelo **sin penalidad** contra **Ridge (L2)** y **LASSO (L1)** sobre una matriz X de **16 variables socioeconómicas sin ninguna variable de ingreso**. Siguiendo el enfoque de Maurizio & Monsalvo, entrenamos con 2024 y evaluamos sobre 2025, y para el panel inter-anual (MM) sumamos la informalidad del año previo. La penalidad óptima por validación cruzada 5-fold resulta **casi nula** para ambas penalidades ($\lambda_{cv} = 10^{-5}$): con $n \gg p$ (≈ 4.435 obs., 17 predictores) no hace falta regularizar y ninguna variable se elimina en el óptimo. Los determinantes estructurales más fuertes son la **persistencia del estado de informalidad**, la **falta de cobertura de salud** y el **perfil etario**.

Validación 2024 (train) vs 2025 (test): diferencia de medias

Construimos la matriz X reutilizando las variables limpiadas en los TP previos y la guardamos como `base_X_2024_16vars.csv` / `base_X_2025_16vars.csv`. **Excluimos toda variable de ingreso** (P21, P47T, ingreso familiar): el ingreso es consecuencia de la informalidad, no causa (causalidad inversa, bad control y leakage casi definicional); de incluirlo, su señal espuria dominaría el camino de LASSO y taparía los determinantes estructurales accionables por política. La Tabla 1 compara las medias de cada característica entre años mediante un test t de Welch.


Variable	Media 2024	Media 2025	Dif (25–24)	p-valor	Sig.
edad	40,40	40,62	+0,22	0,134	ns
edad ²	1.784,2	1.804,9	+20,7	0,102	ns
educ	12,76	12,72	–0,04	0,372	ns
sec_completo	0,753	0,756	+0,003	0,616	ns
universitario	0,277	0,270	–0,007	0,162	ns
mujer	0,475	0,478	+0,003	0,577	ns
casado	0,530	0,523	–0,007	0,238	ns
jefe_hogar	0,496	0,487	–0,008	0,161	ns
nhogar	5,035	5,140	+0,105	0,009	***
horastrab	36,90	37,34	+0,44	0,023	**
jornada_completa	0,590	0,594	+0,005	0,434	ns
pluriempleo	0,112	0,118	+0,006	0,114	ns
PP04C (tamaño)	17,72	18,23	+0,51	0,167	ns
sin_cobertura	0,215	0,217	+0,002	0,763	ns
sector_construcción	0,095	0,093	–0,002	0,595	ns
sector_comercio	0,030	0,030	+0,001	0,778	ns

De las 16 características, solo **dos** muestran diferencias significativas entre años: **nhogar** (tamaño del hogar, +0,11, $p < 0,01$) y **horastrab** (+0,44 hs, $p < 0,05$). El resto es estadísticamente estable. Esta **estabilidad de la distribución de X entre train y test** es justamente lo que vuelve válido el ejercicio de predicción fuera de muestra: las dos diferencias significativas son de magnitud económica menor y no comprometen la transferencia del modelo de 2024 a 2025.

Regresión logística con regularización: Ridge y LASSO


Regularizar consiste en restringir el espacio de coeficientes añadiendo una penalidad a la verosimilitud: introducimos algo de sesgo para reducir drásticamente la varianza (trade-off sesgo-varianza). **Ridge** penaliza la norma L2 ($\Sigma\beta^2$) y encoge los coeficientes de forma suave sin anularlos (solución interior); **LASSO** penaliza la norma L1 ($\Sigma|\beta|$), que al ser no diferenciable en cero produce soluciones de esquina y selecciona variables (las pone exactamente en cero). El parámetro λ regula la intensidad, no la naturaleza de cada método (en scikit-learn, $C = 1/\lambda$). Como Ridge/LASSO no son invariantes a la escala, **estandarizamos solo las variables numéricas y dejamos las dummies en 0/1**

Trayectoria de coeficientes según λ




Con λ pequeño los coeficientes toman su valor de máxima verosimilitud. Al aumentar λ , **LASSO** (panel izquierdo) lleva coeficientes **exactamente a cero** de forma escalonada, descartando primero las variables de señal débil y dejando para el final a **sin_cobertura**, el predictor más robusto, mientras **Ridge** (panel derecho) solo los encoge suavemente hacia cero sin anularlos. La diferencia visual entre el descarte abrupto y la contracción gradual es la firma de cada penalidad.


Penalidad óptima por validación cruzada (5-fold)



Para ambas penalidades la validación cruzada selecciona $\lambda_{cv} = 10^{-5}$ (extremo inferior de la grilla), con error de clasificación mínimo de **7,3%**. Es decir, **la penalidad óptima es prácticamente nula**: la curva de error es plana en la zona de λ bajos y solo se dispara cuando $\lambda > 10$, al punto en que la penalidad empieza a destruir señal útil. El motivo es estructural: con $n \gg p$ (≈ 4.435 observaciones frente a 17 predictores, ratio $\approx 260:1$) el modelo no está sobre-parametrizado, así que no hay varianza excesiva que regularizar. (Nota metodológica: el CV optimiza accuracy y la clase informal es solo el 8,7%, por lo que la curva es poco sensible; la conclusión — λ mínimo, $n \gg p$ — es robusta, pero métricas como AUC o log-loss serían más informativas ante el desbalance.)



Comparación de coeficientes: sin penalidad vs L1 vs L2



¿Cómo son los coeficientes regularizados respecto al logit sin penalidad? Prácticamente **idénticos**. Como λ_{cv} es mínimo, ni Ridge encoge ni LASSO elimina: los tres modelos coinciden hasta el tercer decimal. Esto es la confirmación empírica del resultado de B.2: cuando no hace falta regularizar, la solución penalizada converge a la de máxima verosimilitud.

¿La penalidad L2 elimina variables? No. Ridge nunca anula coeficientes por construcción (solo los encoge), y aquí con λ casi nulo, ni siquiera los encoge de forma apreciable. Tampoco LASSO descarta ninguna en el óptimo.

Conclusiones socioeconómicas

Más allá del método, el modelo entrega una radiografía de los determinantes de la informalidad:

- **Persistencia del estado.** Haber sido informal el año previo es, por lejos, el mejor predictor de seguir siéndolo: la informalidad es un estado persistente, no transitorio. Es una trampa de la que se sale con dificultad, lo que justifica políticas de formalización sostenidas en el tiempo más que intervenciones puntuales.
- **Falta de cobertura de salud.** Segunda señal más fuerte y la última que LASSO descartaría. Refleja la naturaleza casi definicional de la informalidad: el empleo no registrado va de la mano de la ausencia de obra social y aportes.
- **Perfil etario en U (edad $-1,43$; edad² $+1,15$).** La informalidad es alta entre los más jóvenes, cae hacia la adultez y vuelve a subir en edades avanzadas —patrón típico de inserción precaria al inicio y al final de la vida laboral.
- **Educación universitaria ($+0,56$, $p=0,045$).** Asociada a mayor informalidad una vez controlado el resto: consistente con una informalidad “de salida” o de cuentapropismo profesional (Perry et al., 2007), distinta de la informalidad de subsistencia.
- **Género (mujer, $-0,41$).** Entre asalariados, las mujeres muestran menor probabilidad de informalidad que los varones, condicionando por edad, educación y sector.

Herramientas de IA

La IA (Claude, Anthropic) fue más útil en lo **conceptual** y en el **diagnóstico de errores de código**: aclarar por qué se excluye el ingreso de X, la intuición geométrica de Ridge vs LASSO, qué se promedia en el CV, y resolver el error Singular matrix y la separación correcta numéricas/dummies para estandarizar. Donde fue **menos efectiva** fue en decisiones que dependían del contexto específico de nuestros datos, elegir el set final de variables o juzgar el desbalance de clases, que requirieron criterio propio y lectura de las consignas.

Prompts de IA utilizados

LLM utilizada: **Claude (Anthropic — claude-opus-4-8)**. Transcripción textual y en orden de uso; tras cada prompt, una breve nota de en qué fue útil y en qué no.

1. (Conceptual) “¿Por qué la matriz X no puede incluir variables de ingreso si justamente el ingreso está muy correlacionado con la informalidad? ¿No mejoraría la predicción incluirlo? Explicámelo conceptualmente.”
2. (Código) “Al estimar el logit con statsmodels me da el error 'Singular matrix'. ¿Por qué pasa y cómo lo soluciono?”
3. (Conceptual) “Ridge y LASSO usan los dos un parámetro λ y los dos achican los coeficientes, pero LASSO termina poniendo algunos en cero exacto y Ridge no. ¿Por qué pasa esto? ¿La diferencia está en λ o en otra cosa? Explicámelo con la intuición y con la geometría.”
4. (Conceptual) “En nuestro Cross-validation de 5-fold, ¿qué es exactamente lo que se promedia y de dónde sale el λ óptimo? ¿Por qué la grilla está escrita como $\lambda=10^n$ en vez de probar valores de uno en uno?”
5. (Código) “El LogisticRegressionCV está optimizando 'accuracy', pero como solo el 8,7% de los casos son informales, un clasificador que predice 'todos formales' ya acierta el 91%. ¿Cómo cambio la métrica del scoring del cross-validation para que sea más sensible al desbalance de clases, y qué opciones tengo en scikit-learn?”
6. (Código/Metodológico) “Después de estandarizar solo las numéricas, el λ óptimo de Ridge por CV pasó de 10^1 a 10^{-5} y ahora coincide con LASSO. ¿Es correcto? ¿Por qué el atributo C_ de LogisticRegressionCV a veces no coincide con el mínimo de la curva de error?”